

Gerenciamento de Dados e Informação

Dados Semiestruturados & XML



Fernando Fonseca **Ana Carolina Robson Fidalgo**



Dados na Web

- O objetivo é integrar todos os tipos de informação, incluindo informação não estruturada
 - ◆Informação irregular ou ausente
 - olnformação com estrutura não conhecida completamente
 - ◆ Esquemas que evoluem dinamicamente



Representação de Dados para Web/BD

- Necessidades de modelar
 - A própria Web
 - ◆ A estrutura de Web sites
 - A estrutura interna de páginas da Web
 - ●O conteúdo do Web site em menor granularidade



Web X Banco de Dados

- Web: enorme banco de dados
- A maioria dos documentos é gerada para ser disponibilizada para leitura
- Alguns destes documentos foram gerados a partir de consultas a BD
- Dados podem ser extraídos das páginas Web para serem utilizados por outros programas



Web X Banco de Dados

Web

- Padrão simples e universal para troca de informações
- Informações decompostas como unidades que possam ter nome (URL) e ser transmitidas (HTTP)
- Estrutura da informação (HTML)

Banco de Dados

- Esquemas (relacional) e diagramas (E-R) para descrever a estrutura
- Linguagem de consulta, controle de concorrência, recuperação e integridade
- Separa a visão lógica da implementação física



Estrutura dos Dados

- Dados Estruturados (BD)
- Dados Semi-estruturados (XML)
- Dados Não Estruturados (HTML)



Dados Estruturados

- Os SGBD trabalham com dados bem estruturados
 - Esquema pré-definido
 - ◆ Todos os dados de acordo com o esquema
- SGBD precisam do esquema para
 - Armazenar e indexar dados
 - Processar consultas e atualizações
- Usuários precisam do esquema para formular consultas e atualizações



Dados Semi-estruturados

- Atualmente, muitas informações são semiestruturadas
 - ◆Ausência de uma estrutura regular, ou a estrutura é capaz de evoluir de forma imprevisível
 - Dados podem ser incompletos
 - ◆SGBD e usuários não precisam conhecer completamente a estrutura



Dados Semi-estruturados

- Fontes de dados semi-estruturados
 - Integração de dados e ambientes de troca de informação
 - Dados extraídos da Web
 - XML (eXtensible Markup Language)
- Características dos Dados Semi-estruturados
 - Estrutura irregular (dados heterogêneos)
 - Modelar e consultar esta estrutura irregular é essencial



Dados Semi-estruturados

- Características dos Dados Semi-estruturados (Cont.)
 - A estrutura pode ser implícita
 - Alguma computação é necessária para
 - A correspondência entre a estrutura e a representação lógica dos dados nem sempre é imediata



Dados Semi-estruturados

- A estrutura pode ser parcial
 - Parte dos dados pode não ter estrutura (ex: bitmaps)
 - ♦ Outros podem ter uma estrutura "fraca" (ex: textos)
- Tipos são apenas indicativos
 - Ao contrário do sistema de tipos rígido das aplicações de BD

11








XML - Extensible Markup Language

- Desenvolvida em 1996 pelo XML Working Group formado sob a proteção do World Wide Web Consortium (W3C)
- Linguagem de marcadores
 - Para descrever informações
 - Estrutural e semântica, não uma linguagem de formatação
- Padrão XML
 - Para representação de dados
 - Para troca de informações





Qual a origem de XML?


- XML é um subconjunto de SGML ISO8879
- SGML (Standard Generalized Markup Language) Uma metalinguagem por meio da qual se pode definir linguagens de marcação para documentos
 - ◆Um padrão internacional para a definição de métodos de representação de texto em formato eletrônico
 - Padrão muito poderoso e bastante geral, o que torna complicada a sua implementação


Relação entre SGML, XML e HTML HTML Definition Format (CDF) Text Open Financial **Enconding** SGML XML Exchange Iniative (OFX) (TEI) Chemical Markup DocBook Language (CML)




XML, outra linguagem de marcadores?

- Não!
 - ◆A maioria das linguagens provê um conjunto fixo de marcadores, XML é extensível
 - XML permite a definição de novos marcadores
 - Descrição de documentos XML
 - **DTD** Document Type Definition
 - XML Schema

















Objetivos de XML

- Ser possível usar XML diretamente por toda a Internet
- Dar suporte a uma grande variedade de aplicações
- Ser compatível com SGML
- Ser fácil escrever programas para processar documentos XML



Objetivos de XML

- O número de características adicionais a XML deverá ser o **mínimo** possível
- Documentos XML devem legíveis ser razoavelmente claros
- O projeto de XML deve ser preparado rapidamente
- O projeto de XML deve ser formal e conciso
- Documentos XML devem ser fáceis de criar



Benefícios

- XML é um padrão completamente aberto
- Documentos XML podem ser usados e reusados de diferentes formas e em diferentes formatos
- Os autores de documentos XML podem concentrarse no conteúdo e não na formatação
- Documentos XML são auto-descritíveis
- Documentos XML são como BD de informações
- O conteúdo dos documentos pode ser manipulado e reorganizado pelo browser



Classes de documentos XML

- Documento bem formado
 - ◆Documento que está de acordo com o padrão **XML**
- Documento válido
 - ◆ Documento XML bem formado que está de acordo com a DTD (ou esquema) associada(o)




Produtos para XML


- Ferramentas para criação e modificação de documentos XML
 - Editores de XML
- Ferramentas para criação e modificação de DTD, XSL style sheets, etc.
 - ◆ DTD (editores, geradores)
 - Ferramentas para fazer conversão entre DTD e Esquemas
 - XSL (editores, geradores)



Produtos para XML


- Ferramentas para dar suporte ao gerenciamento e ao armazenamento de documentos XML
 - •Sistemas que armazenam persistentemente documentos XML e oferecem acesso estrutura dos documentos e a seus componentes
 - Utilitários para gerenciamento de documentos
 - Mecanismos de busca para XML
 - SGBD
 - Parsers
 - Browsers








API para XML


 DOM e SAX são API para XML
 Oferecem meios para acessar e manipular o conteúdo de um documento XML
 Oferecem diferentes visões do documento
 ◆ DOM (Document Object Model): visão baseada em árvore
 ◆ SAX (The Simple API for XML): visão baseada em eventos










































































Namespace default

É possível declarar um namespace default e ocultar alguns prefixos

http://www.w3.org/HTML/1998/html4 xmlns:xdc="http://www.xml.com/books"> <head><title>Book Review</title></head> <body> <xdc:bookreview>

<xdc:title>XML: A Primer</xdc:title>

....





Namespaces – Nomes universais

- A combinação de um nome local com uma URL é chamada de "nome universal"
- O papel da URL em um nome universal é puramente permitir que as aplicações tenham como identificar unicamente os elementos ou atributos



Esquemas XML - Objetivos

- O propósito de uma linguagem de definição de esquemas é oferecer um conjunto de construtores para definições de esquemas
- Esquemas XML podem ser usados para definir, descrever e catalogar vocabulários para classes de documentos



Linguagens de Esquemas

- DCD [Document Content Description]
- XML-Data Reduced (XDR)
- DDML (Xschema)
- Schema for Object-Oriented XML (SOX)
- W3C XML Schema Definition Language (XSDL)




XML Schema – Sintaxe Básica

- Uma especificação em XML Schema sempre inicia com a tag <schema> e termina com a tag </schema>
- Todas as declarações de elementos, atributos e tipos devem ser inseridas entre estas duas tags



XML Schema – Sintaxe Básica

- Tipos podem ser
 - ◆Simples (simpleType):são tipos básicos como string, date, float, double...
 - Complexos (complexType): definem a estrutura de elementos, ou seja definem características como:
 - Subelementos
 - Atributos
 - Cardinalidades dos subelementos
 - Obrigatoriedade dos atributos





XML Schema – Exemplo 2

Considerando a relação

Filme (mat: number, titulo: varchar2(30), duracao: varchar2(4), genero: varchar2(7))

Criar um XML Schema para um arquivo XML contendo a resposta para: SELECT * FROM Filme;



XML Schema – Exemplo 2

<?xml version="1.0" encoding="utf-8"?>

<xsd:schema xmlns:xsd="http://www.w3.org/2000/10/XMLSchema">

<xsd:element name="filme">

<xsd:complexType>

<xsd:sequence>

<xsd:element name="mat" type="xsd:integer"/>

<xsd:element name="titulo" type="xsd:string"/>

<xsd:element name="duracao" type="xsd:string"/>

<xsd:element name="genero" type="xsd:string"/>

</xsd:sequence>

</xsd:complexType>

</xsd:element>

</xsd:schema>



XML Schema - Sintaxe Básica


- Os tipos de dados definidos em um esquema podem ser usados para a definição de elementos e atributos
 - ◆Os tipos complexos (complexType) podem ser usados apenas para definição de **elementos**
 - ◆Os tipos simples (simpleType) podem ser usados para definição tanto de elementos como de atributos


71





XML Schema – Sintaxe Básica


- XML Schema permite a definição de cardinalidade para um elemento
 - O atributo minOccurs determina o número mínimo de ocorrências de um elemento
 - O atributo maxOccurs determina o número máximo de ocorrências de um elemento










































```
Exemplo de CSS

inicio {
    display: block;
    padding: 0.3em;
    font: bold x-large sans-serif;
    color: white;
    background-color: #C6C;
    }

livro {
    display: block;
    font: normal medium sans-serif;
    }
```

