

Compiladores

(IF688)

Leopoldo Teixeira
lmt@cin.ufpe.br | @leopoldomt

Geração de Código



Geração de Código

- O processo de geração se beneficia de contexto
- Podemos fazer um trabalho melhor na geração de código, se soubermos como os valores são definidos e usados
- Para isto podemos nos beneficiar de blocos básicos
 - sequências máximas de instruções de três endereços consecutivas

Gerando blocos básicos

- Dada uma sequência de instruções de três endereços, a ideia é particioná-la em uma lista de blocos básicos
- O processo para tanto, se dá pela identificação das instruções *leaders*, isto é, instruções que iniciam blocos básicos
 - a primeira instrução
 - qualquer instrução alvo de um desvio
 - qualquer instrução após um desvio

```
1)  i = 1
2)  j = 1
3)  t1 = 10 * i
4)  t2 = t1 + j
5)  t3 = 8 * t2
6)  t4 = t3 - 88
7)  a[t4] = 0.0
8)  j = j + 1
9)  if j <= 10 goto (3)
10) i = i + 1
11) if i <= 10 goto (2)
12) i = 1
13) t5 = i - 1
14) t6 = 88 * t5
15) a[t6] = 1.0
16) i = i + 1
17) if i <= 10 goto (13)
```

Usando blocos básicos

- Podemos saber quando o valor de uma variável será usado novamente
- Essencial para gerar código e alocar registradores
- A ideia é calcular *liveness* das variáveis entre blocos (como visto na aula de otimização)
- Podemos montar ou não o *flow graph*

Gerando Código

- Podemos descrever um algoritmo simples para gerar código a partir de um único bloco básico
- Considera cada instrução por vez e guarda quais valores estão em quais registradores, para evitar gerar *loads* e *stores* desnecessários

Usando registradores

- Na maioria das arquiteturas de máquina, alguns (ou todos) os operandos de uma operação devem estar em registradores
- Registradores servem bem para armazenar temporários — valores resultantes da avaliação de uma subexpressão, enquanto a maior está sendo avaliada, ou variáveis usadas apenas no bloco básico

Usando registradores

- Também são úteis para guardar valores (globais) que são computados em um bloco básico e usados em outros blocos
 - por exemplo, índices de loop
- Utilizados para auxiliar no gerenciamento de memória em tempo de execução, como é o caso de ponteiros para o topo da pilha de execução

Assumptions

- Há uma quantidade de registradores disponíveis suficiente para armazenar os valores usados dentro do bloco
- Este conjunto não inclui os registradores reservados para variáveis globais e gerenciamento da pilha
- O bloco básico já foi otimizado, eliminando subexpressões em comum, por exemplo

Assumptions

- Para cada operador há exatamente uma instrução de máquina que leva os operandos aos registradores, executa a operação e armazena resultado em registrador
 - **LD** *reg, mem*
 - **ST** *mem, reg*
 - **OP** *reg, reg, reg*

Visão Geral

- A geração de código considera cada instrução e decide que *loads* são necessários para colocar os operandos em registradores
- Após gerar os *loads* o código para a operação em si é então gerado
- Se houver necessidade de armazenar o resultado em uma posição de memória, o código de *store* também é gerado

Descriptors

- Para tomar decisões sobre o que gerar, precisamos de estruturas de dados auxiliares para informar quais variáveis tem o valor atualmente em qual registrador
- Também precisamos saber se a posição de memória associada com uma dada variável tem atualmente o valor correto para esta variável
 - um novo valor para a variável pode ter sido computado em um registrador e ainda não armazenado em memória

Register Descriptors

- Para cada registrador disponível, um *register descriptor* guarda os nomes de variáveis cujo valor atual está no registrador
- Como estamos gerando código apenas para um único bloco básico, inicialmente estes *descriptors* estão vazios
- Na medida que a geração de código vai prosseguindo, vai guardar o valor de zero ou mais nomes de variáveis

Address Descriptors

- Para cada variável do programa, um *address descriptor* guarda a posição (ou posições) de memória onde o valor atual da variável pode ser encontrado
- Esta posição pode ser um registrador, um endereço na memória, uma posição na pilha...
- A informação pode ser armazenada na tabela de símbolos para aquele nome de variável

Compiladores

(IF688)

Leopoldo Teixeira
lmt@cin.ufpe.br | @leopoldomt

$$t = a - b$$

$$u = a - c$$

$$v = t + u$$

$$a = d$$

$$d = v + u$$

R1	R2	R3

a	b	c	d	t	u	v
a	b	c	d			

$t = a - b$

LD R1, a

LD R2, b

SUB R2, R1, R2

$u = a - c$

$v = t + u$

$a = d$

$d = v + u$

R1	R2	R3
a	t	

a	b	c	d	t	u	v
a, R1	b	c	d	R2		

t = a - b

LD R1, a

LD R2, b

SUB R2, R1, R2

u = a - c

LD R3, c

SUB R1, R1, R3

v = t + u

a = d

d = v + u

R1	R2	R3
u	t	c

a	b	c	d	t	u	v
a	b	c, R3	d	R2	R1	

t = a - b

LD R1, a

LD R2, b

SUB R2, R1, R2

u = a - c

LD R3, c

SUB R1, R1, R3

v = t + u

ADD R3, R2, R1

a = d

d = v + u

R1	R2	R3
u	t	v

a	b	c	d	t	u	v
a	b	c	d	R2	R1	R3

$t = a - b$

LD R1, a

LD R2, b

SUB R2, R1, R2

$u = a - c$

LD R3, c

SUB R1, R1, R3

$v = t + u$

ADD R3, R2, R1

$a = d$

LD R2, d

$d = v + u$

R1	R2	R3
u	a, d	v

a	b	c	d	t	u	v
R2	b	c	d, R2		R1	R3

t = a - b

LD R1, a

LD R2, b

SUB R2, R1, R2

u = a - c

LD R3, c

SUB R1, R1, R3

v = t + u

ADD R3, R2, R1

a = d

LD R2, d

d = v + u

ADD R1, R3, R1

R1	R2	R3
d	a	v

a	b	c	d	t	u	v
R2	b	c	R1			R3

```

t = a - b
    LD R1, a
    LD R2, b
    SUB R2, R1, R2
u = a - c
    LD R3, c
    SUB R1, R1, R3
v = t + u
    ADD R3, R2, R1
a = d
    LD R2, d
d = v + u
    ADD R1, R3, R1
//fim do bloco
    ST a, R2
    ST d, R1

```

R1	R2	R3
d	a	v

a	b	c	d	t	u	v
a, R2	b	c	d, R1			R3

A Geração de Código

- Uma parte essencial do algoritmo é a função *getReg(I)*, que seleciona registradores para cada posição de memória associada com instrução *I*
- Esta função tem acesso aos descriptors para todas as variáveis do bloco básico em questão,
 - pode ter acesso à informações de fluxo de dados como quais variáveis estão vivas

A Geração de Código

- Vamos discutir *getReg(I)*, após apresentar como a utilizamos para gerar código
- De acordo com as nossas *assumptions*, há registradores suficientes para os dados do bloco básico
- Embora não saibamos o total de registradores disponíveis, assumimos que há registradores para suprir qualquer operação do bloco

Operações

- Para uma instrução do tipo $\mathbf{x} = \mathbf{y} + \mathbf{z}$
 - Use $getReg(\mathbf{x}=\mathbf{y}+\mathbf{z})$ para selecionar registradores para \mathbf{x} , \mathbf{y} e \mathbf{z} ($\mathbf{R_x}$, $\mathbf{R_y}$, $\mathbf{R_z}$)
 - Se \mathbf{y} não está em $\mathbf{R_y}$ (*register descriptor*), emita uma instrução **LD** $\mathbf{R_y}$, $\mathbf{y'}$, onde y' é uma posição de memória para y (de acordo com o *address descriptor*)
 - Similarmente, se z não está em $\mathbf{R_z}$, emita a instrução de carregamento correspondente **LD** $\mathbf{R_z}$, $\mathbf{z'}$
 - Emita a instrução **ADD** $\mathbf{R_x}$, $\mathbf{R_y}$, $\mathbf{R_z}$

Cópia

- Para uma instrução do tipo $\mathbf{x} = \mathbf{y}$
 - Use $getReg(\mathbf{x}=\mathbf{y})$ para obter registradores para \mathbf{x} e \mathbf{y} ($\mathbf{R_x}, \mathbf{R_y}$)
 - Assumimos que esta função sempre retorna o mesmo registrador para \mathbf{x} e \mathbf{y}
 - Se \mathbf{y} não está em $\mathbf{R_y}$, emitimos instrução $\mathbf{LD \ R_y, \ y}$
 - É preciso atualizar o register descriptor de $\mathbf{R_y}$ para incluir \mathbf{x} como um dos valores encontrados lá

Finalizando o Bloco Básico

- As variáveis usadas no bloco podem acabar com seus valores apenas disponíveis em registradores
- Se for um temporário, tudo bem
- Se a variável estiver viva na saída do bloco, ou se não soubermos com certeza, precisamos assumir que o valor é necessário após saída
- Neste caso, para cada variável x cujo *address descriptor* não informa que seu valor está na memória, precisamos gerar **ST x , R**

Gerenciando *Descriptors*

- Na medida que são gerados *loads*, *stores* e outras instruções, precisamos atualizar os *descriptors* de acordo com regras
- Desta forma, temos como saber quais registradores estão com quais variáveis, etc

Gerenciando *Descriptors*

- Para uma instrução do tipo **LD R, x**
 - Altere o *register descriptor* de **R** para que contenha apenas **x**
 - Altere o *address descriptor* de **x** para adicionar **R** como localização adicional
 - Remova **R** do *address descriptor* de qualquer outra variável diferente de **x**

Gerenciando *Descriptors*

- Para uma instrução do tipo **ST *x*, R**
 - Altere o *address descriptor* de *x* para incluir sua própria localização na memória

Gerenciando *Descriptors*

- Para uma operação do tipo **ADD** $\mathbf{R_x}, \mathbf{R_y}, \mathbf{R_z}$
 - Altere o *register descriptor* de $\mathbf{R_x}$ para que contenha apenas \mathbf{x}
 - Altere o *address descriptor* de \mathbf{x} para que $\mathbf{R_x}$ seja a única localização de \mathbf{x}
 - Remova $\mathbf{R_x}$ do *address descriptor* de qualquer outra variável diferente de \mathbf{x}

Gerenciando *Descriptors*

- Para operação de cópia $\mathbf{x} = \mathbf{y}$, após gerar o código para carregar \mathbf{y} em \mathbf{R}_y , caso necessário, e após gerenciar *descriptors* para os *loads*:
 - Adicione \mathbf{x} ao *register descriptor* de \mathbf{R}_y
 - Altere o *address descriptor* de \mathbf{x} para que sua única localização seja \mathbf{R}_y

Função *getReg*

- Existem várias opções para implementar esta função para uma instrução *I*
- Considere uma operação como $\mathbf{x} = \mathbf{y} + \mathbf{z}$
- Precisamos escolher um registrador para \mathbf{y} e outro para \mathbf{z}
- As questões são as mesmas, portanto vamos focar na escolha de um registrador pra \mathbf{y}

Função *getReg*

- Se y já está em um registrador, escolha um dos registradores contendo y como R_y
- Se y não está em um registrador, mas há algum vazio, escolha este como R_y
- Se não houver registradores vazios, precisamos de qualquer forma de um registrador para y
- Seja R o registrador candidato e suponha que v é uma das variáveis que estão no *register descriptor*
- Existem algumas possibilidades...

Possibilidades

1. Se o *address descriptor* de \mathbf{v} diz que \mathbf{v} está em algum outro lugar além de \mathbf{R} , ok
2. Se \mathbf{v} for \mathbf{x} , que é a variável sendo computada pela instrução, e \mathbf{x} não for um dos operandos ($\mathbf{x} \neq \mathbf{z}$), então ok
3. Se \mathbf{v} não é usada mais adiante, ou seja, após instrução I , não há mais usos de \mathbf{v} , e \mathbf{v} está viva na saída do bloco, ela foi recomputada, então ok
4. Se não casar nenhum dos três casos acima, precisamos gerar a instrução de *store* para \mathbf{v} , colocando uma cópia dela em sua posição de memória (*spill*)

Função *getReg*

- Agora, considere a escolha do registrador \mathbf{R}_x
- As questões são bem semelhantes às de \mathbf{R}_y , as únicas diferenças são:
 - Já que um novo valor pra x está sendo computado, um bom candidato é um registrador que apenas armazena x
 - Se y não é usada após instrução I , e \mathbf{R}_y tem apenas y após o *load*, \mathbf{R}_y pode ser usada como \mathbf{R}_x , e o mesmo se aplica para \mathbf{R}_z